FPT UNIVERSITY FALL 2026

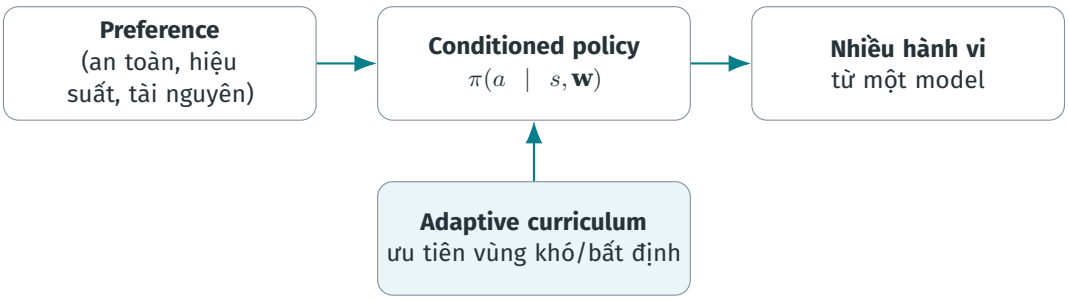
**ĐỀ XUẤT ĐỒ ÁN CUỐI KỲ**

Reinforcement Learning — REL301m

# HỌC TĂNG CƯỜNG ĐA MỤC TIÊU VỚI CHƯƠNG TRÌNH HUẤN LUYỆN PREFERENCE THÍCH NGHI

## Adaptive Preference Curriculum for Zero-Shot Multi-Objective Reinforcement Learning under Environment Shift

**Ý tưởng cốt lõi.** Huấn luyện một policy duy nhất có khả năng thay đổi hành vi theo nhiều mức ưu tiên giữa các mục tiêu xung đột, tổng quát sang preference chưa từng thấy và duy trì hiệu quả khi động lực học của môi trường thay đổi. Phương pháp đề xuất tập trung dữ liệu huấn luyện vào các vùng preference mà agent đang yếu, chưa được bao phủ hoặc có độ bất định cao.




**Nhóm thực hiện:** _____
**Thành viên 1:** _____
**Thành viên 2:** _____
**Thành viên 3:** _____
**Giảng viên:** _____

Tháng 10 năm 2026

# Thông tin đề xuất

| Hạng mục | Nội dung |
|---|---|
| Lĩnh vực | Multi-Objective Reinforcement Learning; generalization; curriculum learning; uncertainty estimation |
| Thời gian | 8 tuần |
| Nhân sự | 3 sinh viên |
| Môi trường chính | MO-LunarLander và Minecart; MO-Highway là mục tiêu mở rộng |
| Đóng góp dự kiến | Adaptive preference curriculum dựa trên conditioning gap, độ bất định và mức độ bao phủ |
| Baseline chính | Independent scalarized DQN, Uniform-PCQN, Envelope Q-Learning, GPI-LS |
| Thước đo chính | Hypervolume, utility trên unseen preferences, worst-decile regret, robustness dưới dynamics shift |
| Tài nguyên | CPU hoặc một GPU phổ thông; không yêu cầu robot thật hay foundation model |
| Đầu ra | Mã nguồn tái lập, báo cáo dạng paper, bảng/biểu đồ, checkpoint và video demo tương tác |

**Khuyến nghị phê duyệt.** Đề tài cân bằng tốt giữa tính mới, chiều sâu kỹ thuật và khả năng hoàn thành trong 8 tuần. Phạm vi cốt lõi được giới hạn ở hai môi trường có observation dạng vector và action rời rạc; các thí nghiệm locomotion hoặc autonomous driving chỉ được thực hiện sau khi hoàn thành đầy đủ baseline, ablation và thống kê của phạm vi chính.

# Mục lục

**Thông tin đề xuất** i

**1 Tóm tắt đề xuất** 1

**2 Bối cảnh và động lực nghiên cứu** 1
2.1 Giới hạn của reward vô hướng cố định . . . 1
2.2 Multi-Objective Reinforcement Learning . . . 1
2.3 Liên hệ với nội dung môn REL301m . . . 2

**3 Mục tiêu, câu hỏi nghiên cứu và giả thuyết** 2
3.1 Mục tiêu tổng quát . . . 2
3.2 Mục tiêu cụ thể . . . 2
3.3 Câu hỏi nghiên cứu . . . 2
3.4 Giả thuyết chính . . . 3

**4 Phạm vi và bài toán nghiên cứu** 3
4.1 Mô hình Multi-Objective MDP . . . 3
4.2 Môi trường chính . . . 4
4.3 Các dạng generalization . . . 4

**5 Phương pháp đề xuất** 4
5.1 Preference-conditioned vector Q-network . . . 4
5.2 Pareto archive . . . 4
5.3 Adaptive preference curriculum . . . 5
5.4 Luồng xử lý . . . 5

**6 Baseline và thiết kế thí nghiệm** 5

6.1 Baseline bắt buộc . . . 6
6.2 Ma trận thí nghiệm cốt lõi . . . 6
6.3 Metrics . . . 6
6.4 Ablation studies . . . 7
6.5 Phân tích thống kê . . . 7

**7 Tiêu chí thành công và đầu ra 7**
7.1 Ba mức hoàn thành . . . 7
7.2 Deliverables . . . 7
7.3 Giá trị khi giả thuyết không được xác nhận . . . 8

**8 Kế hoạch thực hiện trong 8 tuần 8**

**9 Phân công nhóm 9**

**10 Tài nguyên, chi phí và khả năng tái lập 9**
10.1 Hạ tầng dự kiến . . . 9
10.2 Nguyên tắc tái lập . . . 9

**11 Rủi ro và phương án giảm thiểu 10**

**12 Đóng góp kỳ vọng và lộ trình paper 10**
12.1 Đóng góp kỳ vọng . . . 10
12.2 Mức độ sẵn sàng công bố . . . 10

**13 Kết luận 11**

**Tài liệu tham khảo 12**

**A Cấu hình khởi đầu cho pilot 13**

**B Reproducibility checklist 13**

# 1 Tóm tắt đề xuất

Phần lớn các bài toán Reinforcement Learning (RL) trong giáo trình biểu diễn mục tiêu bằng một reward vô hướng cố định. Cách biểu diễn này buộc nhà thiết kế phải xác định trước sự đánh đổi giữa nhiều yêu cầu có thể xung đột, ví dụ giữa tỷ lệ hoàn thành nhiệm vụ, mức độ an toàn, tốc độ và chi phí tài nguyên. Khi mức ưu tiên thay đổi, một policy thông thường thường phải được hiệu chỉnh reward và huấn luyện lại.

Đề tài này nghiên cứu một bài toán hiện đại hơn: huấn luyện một *preference-conditioned policy* duy nhất, nhận cả trạng thái $s$ và vector preference $\mathbf{w}$, từ đó thay đổi hành vi theo yêu cầu của người dùng mà không cần tái huấn luyện. Bên cạnh khả năng tổng quát sang preference chưa từng xuất hiện trong tập huấn luyện, đề tài còn đánh giá policy dưới các thay đổi về động lực học như trọng lực, gió, điều kiện ban đầu hoặc cấu hình tài nguyên.

Đóng góp kỹ thuật đề xuất là một *adaptive preference curriculum*. Thay vì lấy preference hoàn toàn đồng đều trong quá trình huấn luyện, phương pháp duy trì một tập ứng viên và tăng xác suất chọn những vùng mà policy hiện tại: (i) kém hơn các policy đã lưu trong Pareto archive; (ii) có độ bất định cao theo bootstrap ensemble; hoặc (iii) chưa được lấy mẫu đủ gần đây. Phương pháp sẽ được so sánh với uniform preference sampling và các MORL baseline mạnh dưới cùng ngân sách tương tác môi trường.

> **Câu hỏi trung tâm:** Với cùng số lượng environment interactions, adaptive preference curriculum có cải thiện Pareto coverage, utility trên unseen preferences và độ bền vững dưới dynamics shift so với uniform preference sampling hay không?

# 2 Bối cảnh và động lực nghiên cứu

## 2.1 Giới hạn của reward vô hướng cố định

Trong RL một mục tiêu, agent tối đa hóa kỳ vọng tổng reward chiết khấu:

$$J(\pi) = \mathbb{E}_{\pi}\left[\sum_{t=0}^{T} \gamma^t r_t\right]. \tag{1}$$

Nếu một nhiệm vụ có nhiều tiêu chí, cách phổ biến là gộp chúng bằng các hệ số cố định:

$$r_t = \lambda_1 r_t^{\text{task}} - \lambda_2 c_t^{\text{safety}} - \lambda_3 c_t^{\text{resource}}. \tag{2}$$

Cách làm này có ba nhược điểm: (i) các hệ số $\lambda$ khó lựa chọn; (ii) một policy chỉ phản ánh một cấu hình ưu tiên; và (iii) thay đổi hệ số thường đòi hỏi huấn luyện lại. Reward scalar cũng che khuất thông tin về trade-off: hai policy có cùng tổng reward nhưng có thể có mức an toàn hoặc tiêu thụ tài nguyên rất khác nhau.

## 2.2 Multi-Objective Reinforcement Learning

Trong Multi-Objective RL (MORL), reward là một vector $\mathbf{r}_t \in \mathbb{R}^d$. Mục tiêu không còn là tìm duy nhất một policy tối ưu tuyệt đối mà là học một tập hoặc một policy có khả năng biểu diễn nhiều phương án không bị trội (Pareto-optimal). Người dùng cung cấp preference $\mathbf{w}$ để xác định trade-off mong muốn tại thời điểm triển khai.

MO-Gymnasium và MORL-Baselines, được chuẩn hóa trong công trình NeurIPS 2023 [1], cung cấp môi trường, thuật toán và metric tái lập cho hướng nghiên cứu này. Nghiên cứu ICLR 2025 của Teoh và cộng sự [2] cho thấy khả năng tổng quát hóa của MORL qua các cấu hình môi trường vẫn còn hạn chế. Vì vậy, preference generalization kết hợp environment generalization là một khoảng trống nghiên cứu phù hợp với quy mô đồ án.

### 2.3 Liên hệ với nội dung môn REL301m

Đề tài sử dụng trực tiếp nền tảng của môn học nhưng không giới hạn ở slide:

| Nội dung môn học | Mở rộng trong đề tài | Trạng thái |
|---|---|---|
| Q-learning, Bellman update | Vector-valued preference-conditioned Q-function | **Một phần** |
| Function approximation | Mạng neural nhận đồng thời state và preference | **Một phần** |
| Replay và off-policy learning | Relabel transition bằng nhiều preference khi cập nhật | **Một phần** |
| Exploration–exploitation | Curriculum chọn preference khó hoặc bất định | **Không** |
| LunarLander | MO-LunarLander với bốn reward objectives | **Không** |
| Policy/value evaluation | Pareto front, hypervolume, regret và robustness | **Không** |
| Thí nghiệm empirical | Nhiều seed, hold-out preferences, ablation, confidence interval | **Không** |

*Ký hiệu: "Một phần" nghĩa là có nền tảng liên quan nhưng chưa có nội dung MORL; "Không" nghĩa là thành phần mở rộng ngoài giáo trình.*

## 3 Mục tiêu, câu hỏi nghiên cứu và giả thuyết

### 3.1 Mục tiêu tổng quát

Thiết kế và đánh giá một cơ chế preference curriculum thích nghi nhằm cải thiện khả năng bao phủ Pareto front và tổng quát hóa của một policy đa mục tiêu, dưới ngân sách tương tác môi trường cố định.

### 3.2 Mục tiêu cụ thể

1. Xây dựng pipeline MORL tái lập trên MO-LunarLander và Minecart.
2. Triển khai preference-conditioned vector Q-network và uniform-sampling baseline.
3. Thiết kế curriculum kết hợp conditioning gap, bootstrap uncertainty và coverage/recency.
4. So sánh với tối thiểu ba baseline dưới cùng interaction budget.
5. Đánh giá trên preference chưa thấy và các cấu hình dynamics chưa dùng để huấn luyện.
6. Thực hiện ablation, phân tích thống kê, trực quan hóa Pareto front và demo tương tác.

### 3.3 Câu hỏi nghiên cứu

**RQ1 — Hiệu quả trên preference chưa thấy**

Adaptive curriculum có làm tăng hypervolume và giảm scalarized regret trên tập preference hold-out so với uniform sampling không?

**RQ2 — Hiệu quả sử dụng dữ liệu**

Với cùng số environment interactions, curriculum có đạt chất lượng Pareto front nhanh hơn hay không?

**RQ3 — Robustness**

Lợi ích của curriculum có duy trì khi động lực học hoặc cấu hình môi trường thay đổi không?

**RQ4 — Cơ chế tạo ra cải thiện**

Conditioning gap, uncertainty và coverage đóng góp như thế nào; thành phần nào cần thiết và thành phần nào có thể gây tập trung quá mức?

### 3.4 Giả thuyết chính

**H1.** Với cùng tổng số environment interactions, adaptive curriculum sẽ cải thiện tối thiểu 5% normalized hypervolume và giảm worst-decile scalarized regret trên unseen preferences so với uniform preference sampling, trong khi không làm giảm mean nominal utility quá 3%.
**H2.** Curriculum kết hợp gap và uncertainty sẽ ổn định hơn curriculum chỉ dùng một tín hiệu, đặc biệt tại các preference cực biên.
**H3.** Dynamics randomization nhẹ kết hợp curriculum sẽ giảm mức suy giảm hypervolume dưới environment shift, nhưng có thể đánh đổi một phần hiệu quả trên nominal environment.

Ngưỡng 5% và 3% là tiêu chí thực nghiệm được xác định trước để tránh chỉ diễn giải kết quả sau khi quan sát. Nếu khoảng tin cậy không hỗ trợ các ngưỡng này, giả thuyết sẽ không được chấp nhận.

## 4 Phạm vi và bài toán nghiên cứu

### 4.1 Mô hình Multi-Objective MDP

Xét một Multi-Objective Markov Decision Process:

$$\mathcal{M} = (\mathcal{S}, \mathcal{A}, P, \mathbf{r}, \gamma), \tag{3}$$

trong đó $\mathbf{r}(s, a, s') \in \mathbb{R}^d$. Preference $\mathbf{w}$ thuộc simplex:

$$\Delta^{d-1} = \left\{ \mathbf{w} \in \mathbb{R}^d : \; w_i \geq 0, \; \sum_{i=1}^{d} w_i = 1 \right\}. \tag{4}$$

Policy được điều kiện hóa theo preference:

$$\pi_\theta(a \mid s, \mathbf{w}). \tag{5}$$

Trong phạm vi cốt lõi, utility là tuyến tính:

$$J(\pi, \mathbf{w}) = \mathbf{w}^\top \mathbb{E}_\pi \left[ \sum_{t=0}^{T} \gamma^t \tilde{\mathbf{r}}_t \right], \tag{6}$$

với $\tilde{\mathbf{r}}$ là vector reward đã chuẩn hóa bằng scale chỉ xác định từ environment specification và pilot-training split. Chebyshev scalarization được xem là thí nghiệm mở rộng để khảo sát các vùng Pareto front không lồi.

### 4.2 Môi trường chính

| Môi trường | Không gian và objectives | Vai trò |
|---|---|---|
| MO-LunarLander | Observation 8 chiều; 4 action rời rạc; 4 reward dimensions: landing/crash, shaping, main-engine fuel, side-engine fuel | Primary benchmark; nối trực tiếp với bài LunarLander trong môn học; demo dễ hiểu |
| Minecart | Observation 7 chiều; 6 action; 3 objectives: hai loại quặng và nhiên liệu | Secondary benchmark; Pareto front trực quan; reward thưa và trade-off khác LunarLander |
| MO-Highway | Objectives về tốc độ, làn đường và va chạm | Stretch goal sau khi hoàn tất toàn bộ thí nghiệm cốt lõi |

### 4.3 Các dạng generalization

**Preference shift.** Tập test gồm các preference được sinh bằng random seed tách biệt và không xuất hiện trong curriculum-training pool.

**Environment shift.** MO-LunarLander được đánh giá dưới thay đổi về trọng lực, gió, turbulence và phân phối trạng thái khởi đầu. Minecart được đánh giá dưới thay đổi cấu hình bản đồ, phân bố quặng hoặc mức tiêu hao nhiên liệu. Chỉ mức shift đã định nghĩa trước mới được dùng trong báo cáo chính.

**Giới hạn phạm vi.** Đề tài không xử lý ảnh, không huấn luyện foundation model, không triển khai robot thật và không tuyên bố bảo đảm an toàn hình thức. Đây là nghiên cứu empirical về preference coverage và robustness trong simulation.

## 5 Phương pháp đề xuất

### 5.1 Preference-conditioned vector Q-network

Mạng neural nhận $[s, \mathbf{w}]$ và xuất vector action-value cho từng action:

$$\mathbf{Q}_\theta(s, a, \mathbf{w}) \in \mathbb{R}^d. \tag{7}$$

Action được chọn theo scalarized value:

$$a_t = \arg\max_{a \in \mathcal{A}} \mathbf{w}^\top \mathbf{Q}_\theta(s_t, a, \mathbf{w}), \tag{8}$$

kết hợp $\epsilon$-greedy exploration trong giai đoạn huấn luyện.

Với Double-DQN-style target:

$$a^\star = \arg\max_{a'} \mathbf{w}^\top \mathbf{Q}_\theta(s_{t+1}, a', \mathbf{w}), \tag{9}$$

$$\mathbf{y}_t = \mathbf{r}_t + \gamma(1 - d_t)\mathbf{Q}_{\bar{\theta}}(s_{t+1}, a^\star, \mathbf{w}). \tag{10}$$

Loss sử dụng Huber loss theo từng objective. Vì transition lưu vector reward, một transition có thể được cập nhật với nhiều preference khác nhau mà không cần thu thập lại dữ liệu.

### 5.2 Pareto archive

Trong quá trình huấn luyện, hệ thống duy trì archive $\mathcal{A}$ gồm các vector episodic return không bị Pareto-dominated. Archive phục vụ ba mục đích:

- theo dõi sự phát triển của Pareto coverage;
- tính conditioning gap cho preference ứng viên;
- tạo reference set thực nghiệm phục vụ trực quan hóa và regret analysis.

Reference front cuối cùng dùng để báo cáo sẽ được tạo từ hợp của mọi policy/baseline trên training/validation configurations, sau đó Pareto-prune. Nó không được dùng để điều chỉnh phương pháp trong final test.

### 5.3 Adaptive preference curriculum

Cho một pool preference ứng viên $\mathcal{W}$. Tại mỗi curriculum checkpoint, mỗi $\mathbf{w} \in \mathcal{W}$ nhận ba tín hiệu.

**Conditioning gap:**

$$g(\mathbf{w}) = \left[\max_{\mathbf{v}\in\mathcal{A}} \mathbf{w}^\top \mathbf{v} - \mathbf{w}^\top \widehat{\mathbf{v}}_{\pi_\theta(\cdot|\mathbf{w})}\right]_+ . \tag{11}$$

Tín hiệu này phát hiện preference mà conditioned policy hoạt động kém hơn một policy khác đang có trong archive.

**Bootstrap uncertainty:**

$$u(\mathbf{w}) = \mathbb{E}_{s\sim\mathcal{B}}\left[\mathrm{Var}_{k=1}^{K}\left(\mathbf{w}^\top \mathbf{Q}_{\theta_k}(s, a_k^\star, \mathbf{w})\right)\right], \tag{12}$$

với $K = 3$ bootstrap heads trong cấu hình khởi đầu.

**Coverage/recency:** $c(\mathbf{w})$ tăng khi vùng lân cận của $\mathbf{w}$ ít được lấy mẫu hoặc chưa được thăm gần đây.

Sau khi chuẩn hóa ba tín hiệu trên pool hiện tại:

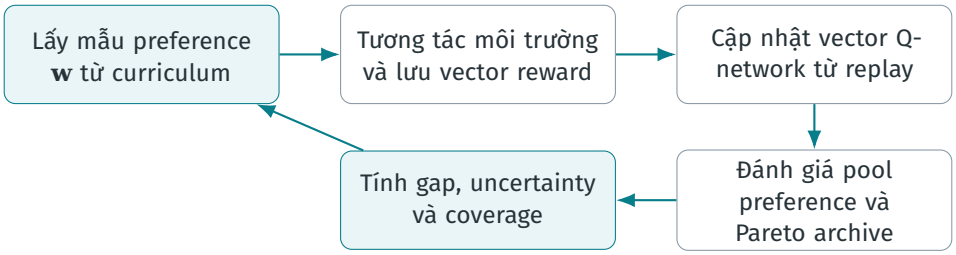
$$z(\mathbf{w}) = \alpha\hat{g}(\mathbf{w}) + \beta\hat{u}(\mathbf{w}) + \eta\hat{c}(\mathbf{w}), \tag{13}$$

và phân phối lấy mẫu:

$$p(\mathbf{w}) = (1-\varepsilon_c)\frac{\exp(z(\mathbf{w})/\tau)}{\sum_{\mathbf{w}'}\exp(z(\mathbf{w}')/\tau)} + \frac{\varepsilon_c}{|\mathcal{W}|}. \tag{14}$$

Thành phần uniform $\varepsilon_c$ ngăn curriculum bỏ quên hoàn toàn một vùng preference. Cấu hình khởi đầu tương đương hỗn hợp 50% uniform, 25% gap và 25% uncertainty/coverage; tỷ lệ cuối cùng được khóa sau pilot và trước final runs.

### 5.4 Luồng xử lý




## 6 Baseline và thiết kế thí nghiệm

## 6.1 Baseline bắt buộc

| Baseline | Mục đích so sánh | Yêu cầu công bằng |
|---|---|---|
| Independent scalarized DQN | Kiểm tra lợi ích của một conditioned policy so với nhiều policy độc lập | Chia tổng interaction budget cho các preference policies |
| Uniform-PCQN | Baseline trực tiếp có cùng kiến trúc nhưng preference được lấy mẫu đều | Giữ nguyên network, optimizer, replay và số updates |
| Envelope Q-Learning | MORL value-based baseline có khả năng thích ứng preference [3] | Dùng cấu hình được khuyến nghị và tuning budget bằng nhau |
| GPI-LS | Strong baseline từ MORL-Baselines, xây dựng coverage set bằng generalized policy improvement | Cùng tổng environment interactions; ghi riêng wall-clock cost |
| Adaptive curriculum | Phương pháp đề xuất | Không dùng final-test preference hoặc final-test dynamics để điều chỉnh |

Pareto-Conditioned Networks có thể được thêm nếu baseline cốt lõi hoàn tất trước Week 5. PPO/DQN scalar thông thường không được xem là baseline đủ để chứng minh đóng góp MORL.

## 6.2 Ma trận thí nghiệm cốt lõi

- 2 environments $\times$ 4–5 methods $\times$ 5 independent training seeds.
- Pilot dùng 3 seeds; final results dùng tối thiểu 5 seeds.
- Tối thiểu 100 unseen preference vectors cho mỗi environment.
- 30–50 evaluation episodes cho mỗi preference/dynamics condition, tùy variance đo được ở Week 2.
- Nominal dynamics và tối thiểu 3 mức shift được định nghĩa trước.
- Training budget khởi đầu: 0.5–1.0 triệu environment steps/method/seed; giá trị cuối được quyết định bằng pilot runtime và learning curves.

## 6.3 Metrics

**Primary metrics:**

1. normalized dominated hypervolume trên unseen preferences;
2. mean scalarized utility trên unseen preferences;
3. worst-decile scalarized regret so với empirical reference set;
4. tỷ lệ suy giảm hypervolume dưới dynamics shift.

**Secondary metrics:**

- inverted generational distance và Pareto-front sparsity;
- LunarLander success/crash rate và fuel per successful landing;
- Minecart quantity/fuel trade-off;
- sample efficiency, wall-clock time và peak memory;
- calibration của bootstrap uncertainty;
- curriculum occupancy: tỷ lệ training samples theo vùng preference.

### 6.4 Ablation studies

Trên môi trường chính MO-LunarLander, thực hiện các biến thể:

1. uniform sampling;
2. gap-only curriculum;
3. uncertainty-only curriculum;
4. gap + uncertainty + coverage;
5. full method nhưng không dùng bootstrap ensemble;
6. full method có/không có dynamics randomization;
7. tùy thời gian: linear so với Chebyshev scalarization.

Các ablation thứ cấp có thể dùng 3 seeds, nhưng kết luận chính phải dựa trên 5 seeds của full method và uniform baseline.

### 6.5 Phân tích thống kê

- Mỗi training seed là một đơn vị lặp độc lập; không coi hàng nghìn evaluation episodes là hàng nghìn training replicates.
- Báo cáo mean, median, standard deviation và 95% bootstrap confidence interval.
- Với cùng seed/configuration, báo cáo paired seed-level differences.
- Primary comparison dùng permutation test hoặc Wilcoxon signed-rank tùy phân phối và số seed.
- Nếu kiểm định nhiều environment/metric, dùng Holm correction.
- Công bố toàn bộ seed và learning curve; không loại seed do kết quả thấp. Chỉ loại lỗi thực thi có log chứng minh.

## 7 Tiêu chí thành công và đầu ra

### 7.1 Ba mức hoàn thành

| Mức | Điều kiện | Ý nghĩa |
|---|---|---|
| Minimum viable project | Hai môi trường chạy ổn định; Uniform-PCQN và ít nhất hai baseline; unseen-preference evaluation; 5 seeds cho so sánh chính | Đủ để hoàn thành đồ án với bằng chứng thực nghiệm đáng tin cậy |
| Strong course project | Full curriculum; ablation; dynamics shift; statistical analysis; demo preference slider; mã nguồn tái lập | Mức mục tiêu để gây ấn tượng trong môn học |
| Paper-oriented result | Cải thiện nhất quán qua hai môi trường và nhiều shift; giải thích cơ chế; so sánh strong baselines; public code | Đủ nền tảng cho workshop/student paper sau khi mở rộng |

### 7.2 Deliverables

- Repository có cấu hình, seed, script train/evaluate và hướng dẫn tái lập.
- Checkpoint của các phương pháp và raw metrics theo từng seed.

- Báo cáo 8–12 trang theo cấu trúc paper, không tính phụ lục.
- Pareto-front plots, hypervolume curves, regret distributions và robustness heatmaps.
- Ablation table và compute/sample-efficiency table.
- Video hoặc live demo với preference slider.
- Model card ngắn mô tả phạm vi, limitation và các điều kiện thất bại.

### 7.3 Giá trị khi giả thuyết không được xác nhận

Kết quả âm vẫn có giá trị nếu protocol được giữ nguyên. Báo cáo sẽ phân tích liệu curriculum có: tập trung quá mức vào preference cực biên; dùng uncertainty chưa được calibration; gây forgetting ở vùng đã học; hoặc chỉ hữu ích khi số objective nhỏ. Một negative result có kiểm soát và ablation đầy đủ tốt hơn một tuyên bố cải thiện chỉ dựa trên một seed.

## 8 Kế hoạch thực hiện trong 8 tuần

| Tuần | Trọng tâm | Công việc chính | Mốc kiểm tra |
|---|---|---|---|
| 1 | Literature và baseline | Cài MO-Gymnasium/MORL-Baselines; chạy random/scalarized agents; reproduce một MORL baseline; khóa phạm vi | Một baseline học được |
| 2 | Hạ tầng thí nghiệm | Seed/config; preference split; metrics; Pareto archive; evaluation và video pipeline | Biết variance và runtime |
| 3 | Uniform conditioned policy | Vector Q-network; replay với vector reward; unit tests; Uniform-PCQN | Baseline ổn định trên 2 env |
| 4 | Phương pháp đề xuất | Gap, bootstrap uncertainty, coverage; pilot ablation; khóa hyperparameters | Freeze cấu hình final |
| 5 | Main experiments | Chạy 5 seeds cho các phương pháp trên nominal environments | Có learning curves đầy đủ |
| 6 | Generalization | Unseen preferences; dynamics shifts; ablations; optional randomization | Hoàn tất raw results |
| 7 | Phân tích | Confidence intervals; tests; figures; failure analysis; demo video | Bảng kết quả cuối |
| 8 | Báo cáo và trình bày | Viết paper-style report; reproducibility pass; slide và live demo | Nộp report + code + demo |

**Go/no-go gates.** Nếu hết Week 1 chưa reproduce được baseline, chuyển môi trường chính sang MO-MountainCar/Deep Sea Treasure. Nếu hết Week 4 curriculum chưa ổn định, giữ conditioning-gap-only làm phương pháp chính và chuyển ensemble uncertainty thành thí nghiệm mở rộng. Không thêm MO-Highway trước khi kết quả cốt lõi hoàn tất.

# 9 Phân công nhóm

| Vai trò | Trách nhiệm chính | Đầu ra sở hữu |
|---|---|---|
| Thành viên A — Algorithm | Vector Q-network; curriculum; bootstrap heads; unit tests cho Bellman target và action selection | Method implementation; algorithm section; checkpoints |
| Thành viên B — Environment/ Baseline | MO-Gymnasium wrappers; dynamics shifts; Envelope Q-Learning/GPI-LS; reward normalization | Baseline configs; environment section; validation results |
| Thành viên C — Evaluation/ Reproducibility | Experiment launcher; logging; Pareto metrics; statistical tests; plots và video | Evaluation scripts; figures; reproducibility appendix |

Các phần cần phối hợp gồm: xác nhận formulation; khóa metric và hyperparameter trước final runs; code review chéo; giải thích kết quả; và viết limitation. Mỗi thành viên phải tái lập ít nhất một thí nghiệm do thành viên khác phụ trách.

# 10 Tài nguyên, chi phí và khả năng tái lập

## 10.1 Hạ tầng dự kiến

- Python, PyTorch, Gymnasium, MO-Gymnasium và MORL-Baselines.
- Một consumer GPU là đủ; CPU vẫn dùng được cho environment và evaluation.
- Không cần dữ liệu độc quyền, API trả phí, robot thật hoặc cụm GPU.
- Ước tính sơ bộ 20–80 GPU-hours cho core experiments, cần hiệu chỉnh sau Week 2.
- Lưu raw result dạng JSON/CSV và checkpoint theo method/environment/seed.

## 10.2 Nguyên tắc tái lập

- Pin phiên bản package và lưu environment file.
- Tách seed cho training, preference generation, evaluation và environment dynamics.
- Mỗi run có immutable configuration và git commit hash.
- Có script một lệnh để train, evaluate và tái tạo figure.
- Ghi số environment steps, gradient updates, wall-clock và hardware.
- Không chọn checkpoint bằng final-test performance.

# 11 Rủi ro và phương án giảm thiểu

| Rủi ro | Xác suất | Tác động | Giảm thiểu |
|---|---|---|---|
| Baseline không ổn định | Trung bình | Cao | Reproduce trước khi sửa thuật toán; dùng cấu hình public; fallback sang môi trường đơn giản |
| Reward objectives khác scale | Cao | Cao | Freeze normalization từ specification/pilot; báo cả normalized và raw objectives |
| Curriculum tập trung quá mức | Trung bình | Cao | Luôn giữ uniform mixture; giới hạn sampling probability; theo dõi occupancy |
| Uncertainty không calibration | Trung bình | Trung bình | Reliability plots; ablation gap-only; tăng bootstrap diversity nếu cần |
| Số run vượt compute budget | Trung bình | Cao | Pilot runtime; ưu tiên core matrix; ablation chỉ trên primary env; không thêm stretch goal sớm |
| Hypervolume nhạy reference point | Trung bình | Trung bình | Khóa reference point trước final runs; báo sensitivity appendix |
| Kết quả không cải thiện | Trung bình | Trung bình | Giữ protocol; phân tích failure modes và negative result; không thay hypothesis sau test |
| Dependency của Box2D/MuJoCo | Thấp–TB | Trung bình | Container/environment lock; Minecart/MO-MountainCar làm fallback |

# 12 Đóng góp kỳ vọng và lộ trình paper

## 12.1 Đóng góp kỳ vọng

1. Một adaptive preference curriculum đơn giản, có thể gắn vào preference-conditioned value-based MORL.
2. Một đánh giá có kiểm soát về preference sampling dưới cùng interaction budget.
3. Phân tích unseen-preference generalization và environment shift trên hai domain có trade-off khác nhau.
4. Bằng chứng ablation về vai trò của gap, uncertainty và coverage.
5. Pipeline và protocol có khả năng tái lập cho nghiên cứu MORL ở quy mô sinh viên.

## 12.2 Mức độ sẵn sàng công bố

**Sau đồ án.** Nếu kết quả nhất quán trên hai môi trường và strong baselines, báo cáo có thể được chuyển thành workshop paper hoặc student research paper sau khi chỉnh sửa.

**Để hướng tới hội nghị chính.** Cần mở rộng sang nhiều môi trường hơn, gồm MO-Highway và ít nhất một continuous-control task; so sánh thêm conditioned-policy algorithms; đánh giá nonlinear utilities; và cung cấp phân tích lý thuyết hoặc empirical principle giải thích khi nào curriculum cải thiện sample allocation.

**Không tuyên bố trước.** Proposal không khẳng định phương pháp chắc chắn vượt baseline. Đóng góp khoa học nằm ở câu hỏi có thể bác bỏ, protocol công bằng và phân tích cơ chế, không chỉ ở một con số cao hơn.

**Thông điệp dự kiến của paper:** “Adaptive allocation of preference-training data improves the worst-covered regions of a multi-objective policy and can enhance zero-shot preference generalization under a fixed interaction budget; however, the benefit depends on uncertainty quality and the geometry of the Pareto front.”

## 13 Kết luận

Đề tài đề xuất một bước chuyển rõ ràng từ RL một mục tiêu trong giáo trình sang bài toán ra quyết định đa mục tiêu, preference-conditioned và có yêu cầu generalization. Phạm vi cốt lõi đủ nhỏ để ba sinh viên hoàn thành trong 8 tuần nhưng vẫn chứa một đóng góp có thể kiểm chứng: phân bổ preference thích nghi dựa trên gap, uncertainty và coverage.

Giá trị của đề tài đến từ bốn yếu tố: câu hỏi nghiên cứu rõ; baseline và metric hiện đại; chi phí tính toán vừa phải; và demo trực quan “một model, nhiều hành vi”. Nếu kết quả tích cực và nhất quán, dự án có đường phát triển thành paper. Nếu kết quả âm, protocol và ablation vẫn có thể tạo ra kết luận có giá trị về giới hạn của adaptive curricula trong MORL.

# Tài liệu tham khảo

## Tài liệu

[1] F. Felten, L. N. Alegre, A. Nowé, A. L. C. Bazzan, E.-G. Talbi, G. Danoy, and B. C. da Silva. *A Toolkit for Reliable Benchmarking and Research in Multi-Objective Reinforcement Learning*. Advances in Neural Information Processing Systems 36, 2023. https://openreview.net/forum?id=jfwRLudQyj

[2] J. Teoh, P. Varakantham, and P. Vamplew. *On Generalization Across Environments in Multi-Objective Reinforcement Learning*. International Conference on Learning Representations, 2025. https://arxiv.org/abs/2503.00799

[3] R. Yang, X. Sun, and K. Narasimhan. *A Generalized Algorithm for Multi-Objective Reinforcement Learning and Policy Adaptation*. Advances in Neural Information Processing Systems 32, 2019. https://arxiv.org/abs/1908.08342

[4] D. M. Roijers, P. Vamplew, S. Whiteson, and R. Dazeley. *A Survey of Multi-Objective Sequential Decision-Making*. Journal of Artificial Intelligence Research, 48:67–113, 2013. https://jair.org/index.php/jair/article/view/10836

[5] R. S. Sutton and A. G. Barto. *Reinforcement Learning: An Introduction*, second edition. MIT Press, 2018. http://incompleteideas.net/book/the-book-2nd.html

[6] Farama Foundation. *MO-Gymnasium: Multi-Objective Gymnasium Environments*. https://mo-gymnasium.farama.org/

[7] L. Alegre and contributors. *MORL-Baselines: Multi-Objective Reinforcement Learning Algorithms*. https://github.com/LucasAlegre/morl-baselines

[8] FPT University. *REL301m Reinforcement Learning: Syllabus, Lecture Slides, Labs and Assignments*. Course materials, Fall 2026.

# A Cấu hình khởi đầu cho pilot

Các giá trị dưới đây là điểm khởi đầu, không phải kết quả tuning. Cấu hình cuối phải được khóa ở cuối Week 4.

| Thành phần | Cấu hình pilot |
|---|---|
| Network | MLP 2 hidden layers, 256 units/layer, ReLU; vector output $\lvert\mathcal{A}\rvert \times d$ |
| Optimizer | Adam, learning rate $3 \times 10^{-4}$ |
| Discount | $\gamma = 0.99$ |
| Replay buffer | $10^5$–$10^6$ transitions tùy environment |
| Batch size | 256 |
| Target update | Soft update hoặc hard update theo baseline reproduction |
| Exploration | $\epsilon$-greedy, decay được khóa từ pilot |
| Preference pool | Dirichlet samples + simplex corners + edge samples |
| Bootstrap heads | $K = 3$ |
| Curriculum update | Mỗi 10–25 nghìn environment steps |
| Curriculum uniform floor | $\varepsilon_c \geq 0.2$ |
| Final training seeds | Tối thiểu 5 |
| Evaluation | Deterministic/greedy policy; preference và environment seeds tách biệt |

# B Reproducibility checklist

☐ Package versions và operating environment được khóa.

☐ Mọi random source đều có seed và được log.

☐ Training/validation/test preferences được tách rõ.

☐ Final-test dynamics không dùng cho tuning.

☐ Total environment interactions bằng nhau giữa methods.

☐ Hyperparameter tuning budget được báo cáo.

☐ Raw per-seed results được giữ lại.

☐ Error bars và confidence intervals xuất hiện trên figure chính.

☐ Failed execution được phân biệt với low-performing seed.

☐ Script tạo lại bảng và figure từ raw results được cung cấp.

☐ Demo dùng đúng checkpoint đã báo cáo, không chọn thủ công trajectory đẹp nhất.

☐ Limitation và negative results được ghi rõ.

— Hết đề xuất —

Tài liệu này được thiết kế để có thể cập nhật tên nhóm, giảng viên và cấu hình pilot trước khi nộp chính thức.